



DEMOCRITUS
UNIVERSITY
OF THRACE

DEPARTMENT OF
ELECTRICAL & COMPUTER
ENGINEERING

Ανάλυση και Σύνθεση Πολύπλοκων Ηλεκτρονικών Συστημάτων

Report Άσκησης 19: Χρήση Κυψελιδωτών
Αυτομάτων Μάθησης για Πλοήγηση Ρομπότ

Ονοματεπώνυμο: Δημήτριος Λίλλης, Αντώνης Θεμελής

A.M. : 58598,58565

Υπ. Καθηγητής: Γεώργιος Συρακούλης

Περιεχόμενα

1.	Εισαγωγή.....	3
2.	Θεωρητικό Υπόβαθρο	3
2.1.	Τι είναι ένα Κυψελιδωτό Αυτόματο;	3
2.2.	Ενισχυτική Μάθηση και Q-Learning	4
2.3.	Χρήση CA στη Ρομποτική	6
3.	Περιγραφή Υλοποίησης.....	7
3.1.	Περιβάλλον Πλέγματος.....	7
3.2.	Εκπαίδευση με Q-learning	8
3.3.	Κυψελιδωτό Αυτόματο (CA).....	8
4.	Αποτελέσματα και Οπτικοποίηση	9
4.1.	Βέλτιστη Διαδρομή (Q-table).....	9
4.2.	Χάρτης Δραστηριότητας CA.....	10
4.3.	Προσομοιώσεις σε πραγματικό χρόνο.....	11
5.	Προτάσεις βελτίωσης	12
6.	Συμπεράσματα.....	13
7.	Περιγραφή Κύριων Αρχείων Προσομοίωσης	14
8.	Τελικός κώδικας και επεξήγηση	15
9.	Εξέλιξη Υλοποίησης.....	16
10.	Βιβλιογραφία.....	17

1. Εισαγωγή

Σκοπός της εργασίας αυτής είναι η υλοποίηση ενός Κυψελιδωτού Αυτομάτου (ΚΑ) μάθησης για την καθοδήγηση ενός ρομπότ σε έναν στόχο, μέσα σε ένα απλό δυσδιάστατο περιβάλλον πλέγματος, αποφεύγοντας τυχαία τοποθετημένα εμπόδια.

Το ρομπότ μπορεί να πραγματοποιήσει τις εξής απλές ενέργειες μετακίνησης: πάνω, κάτω, αριστερά και δεξιά. Η προσομοίωση περιλαμβάνει την αλληλεπίδραση του ρομπότ με το περιβάλλον, την παροχή ανταμοιβών για προσέγγιση του στόχου και ποινών για πρόσκρουση σε εμπόδια.

Η προσέγγιση αξιοποιεί τον αλγόριθμο Q-learning, βασισμένο σε ενισχυτική μάθηση τύπου reward-punishment, για την εκμάθηση βέλτιστων στρατηγικών πλοήγησης. Η μεθοδολογία εμπνέεται από την ενσωμάτωση CA σε προβλήματα δυναμικής κινητικότητας, σύμφωνα και με τη βιβλιογραφία [Sirakoulis & Adamatzky, 2015].

2. Θεωρητικό Υπόβαθρο

Για την πλήρη κατανόηση του πλαισίου της εργασίας, χρειαζόμαστε και το αντίστοιχο θεωρητικό υπόβαθρο.

2.1. Τι είναι ένα Κυψελιδωτό Αυτόματο;

- Ένα Κυψελιδωτό Αυτόματο [Cellular Automatic (CA)], είναι ένα υπολογιστικό μοντέλο το οποίο αποτελείται από ένα πλέγμα κελιών (ή κυψελών), καθένα από τα οποία βρίσκεται σε μια συγκεκριμένη κατάσταση. Το σύνολο των καταστάσεων εξελίσσεται διακριτά στον χρόνο, σύμφωνα με τοπικούς κανόνες που εξαρτώνται από την κατάσταση του ίδιου του κελιού και των γειτόνων του.

Η βασική μορφή ενός ΚΑ ορίζεται από:

- Ένα πεπερασμένο ή άπειρο πλέγμα (1D, 2D ή 3D)
- Ένα σύνολο πεπερασμένων καταστάσεων
- Ένα νεοκλασικό κανόνα μετάβασης, που εφαρμόζεται ταυτόχρονα σε όλα τα κελιά
- Ένα γείτονα

Στο πλαίσιο ρομποτικής, τα CA χρησιμοποιούνται για να αναπαραστήσουν:

- Το χώρο (πλέγμα)
- Τη δυναμική αλλαγή κατάστασης του περιβάλλοντος (διαδρομές, εμπόδια κλπ.)
- Τη συλλογική συμπεριφορά κινητών πρακτόρων

Σύμφωνα και με σχετική βιβλιογραφία, τα CA επιτρέπουν τη μοντελοποίηση πολυπλοκότητας με απλούς, αποκεντρωμένους μηχανισμούς και είναι ιδιαίτερα κατάλληλα για κατανεμημένα συστήματα λήψης αποφάσεων όπως ομάδες ρομπότ (swarm robotics).

“Cellular automata, with their simplicity and local interactions, serve as a natural computational framework for modeling the dynamic behavior of robotic systems in lattice environments.” – Sirakoulis & Adamatzky, 2015, Introduction, p. 2

2.2. Ενισχυτική Μάθηση και Q-Learning

Η **ενισχυτική μάθηση** (Reinforcement Learning) είναι ένα υπό-παρακλάδι της μηχανικής μάθησης, στο οποίο ένας πράκτορας μαθαίνει πώς να λαμβάνει αποφάσεις μέσω αλληλεπίδρασης με ένα περιβάλλον. Ο πράκτορας επιδιώκει να μεγιστοποιήσει την αθροιστική ανταμοιβή που λαμβάνει, εξερευνώντας διάφορες καταστάσεις και βελτιώνοντας προοδευτικά τη στρατηγική του.

Ο μαθησιακός βρόχος βασίζεται στην:

- Κατάσταση (state): Η τρέχουσα αναπαράσταση του περιβάλλοντος.
- Ενέργεια (action): Η απόφαση που λαμβάνει ο πράκτορας.
- Ανταμοιβή (reward): Αριθμητική τιμή που αντανακλά την ποιότητα της ενέργειας.
- Πολιτική (policy): Η στρατηγική του πράκτορα για επιλογή ενεργειών.
- Λειτουργία μετάβασης (transition function): Η απεικόνιση της αλλαγής κατάστασης λόγω ενέργειας.

Το **Q-learning** είναι ένας από τους πιο διαδεδομένους αλγορίθμους ενισχυτικής μάθησης χωρίς μοντέλο. Στόχος είναι η εκμάθηση μιας συνάρτησης $Q(s, a)$, η οποία εκτιμά την αναμενόμενη συνολική ανταμοιβή που θα λάβει ο πράκτορας ξεκινώντας από την κατάσταση s , εκτελώντας την ενέργεια a , και ακολουθώντας την καλύτερη δυνατή στρατηγική στο μέλλον. Η ενημέρωση q -τιμών γίνεται μέσω κανόνα Bellman (ενώ για τη διερεύνηση του χώρου καταστάσεων, εφαρμόζεται στρατηγική *exploration vs exploitation*, με *ϵ -greedy* μέθοδο).

Στην παρούσα εργασία, το Q-learning αξιοποιείται για να επιτρέψει στο ρομπότ να μάθει μια βέλτιστη πολιτική πλοήγησης μέσα σε πλέγμα με εμπόδια. Ο πράκτορας ξεκινάει χωρίς γνώση του περιβάλλοντος και μαθαίνει μέσα από πολλαπλά επεισόδια, ενημερώνοντας την Q-table. Η απουσία μοντέλου περιβάλλοντος με την ανάγκη για ευελιξία, καθιστά το Q-learning κατάλληλη επιλογή.

“Reinforcement learning algorithms such as Q-learning are particularly effective in environments with partial information or dynamic obstacles.” — Mohemmed et al., 2018

2.3. Χρήση CA στη Ρομποτική

Τα Κυψελιδωτά Αυτόματα (CA) έχουν χρησιμοποιηθεί εκτενώς στη ρομποτική για τη μοντελοποίηση δυναμικών περιβαλλόντων, τον σχεδιασμό διαδρομών και την αποκεντρωμένη λήψη αποφάσεων από πράκτορες (ρομπότ). Η φύση τους, ως συστήματα τοπικής αλληλεπίδρασης με καθολική συμπεριφορά, τα καθιστά κατάλληλα για:

- Χαρτογράφηση χώρου σε μορφή πλέγματος,
- Καταγραφή επισκέψεων και συχνότητας δραστηριότητας,
- Εξομοίωση διάδοσης πληροφορίας (π.χ. "μνήμη" ή ενίσχυση διαδρομής).

Στη ρομποτική πλοήγηση, τα CA μπορούν να χρησιμεύσουν είτε ως:

- Μοντέλο του περιβάλλοντος, όπου κάθε κελί αντιπροσωπεύει μια κατάσταση (π.χ. εμπόδιο, στόχος κλπ),
- είτε ως μηχανισμός επίδρασης στη λήψη απόφασης του πράκτορα, (για π.χ. αυξάνοντας/μειώνοντας την πιθανότητα επιλογής μιας περιοχής ανάλογα με τη δραστηριότητα ή το "μονοπάτι").

Η ενσωμάτωση CA με ενισχυτική μάθηση επιτρέπει υβριδικές στρατηγικές: η τοπική πληροφόρηση του CA μπορεί να τροποποιεί την αντίληψη της ανταμοιβής ή να κατευθύνει την εξερεύνηση.

Τέτοιες προσεγγίσεις έχουν εφαρμογές όπως:

- Swarm robotics: πλήθος ρομπότ που ενεργούν αποκεντρωμένα σε κοινό πλέγμα.
- Διαχείριση χώρων με περιορισμούς: π.χ. αποφυγή συμφόρησης ή "παγίδευσης" σε γωνίες.
- Αυτο-οργανωμένα μονοπάτια: χωρίς explicit path-planning.

“Lattice automata provide an efficient and scalable way to model robot interactions with the environment, enabling adaptive behavior without the need for centralized control.” — Sirakoulis & Adamatzky, 2015

Στην παρούσα εργασία, το CA χρησιμοποιείται κυρίως ως καταγραφέας δραστηριότητας: κάθε φορά που το ρομπότ επισκέπτεται ένα κελί, αυτό ενισχύεται, και με την πάροδο των επεισοδίων διαχέεται στους γείτονες. Αυτή η πληροφορία προσφέρει επιπλέον ερμηνεία της στρατηγικής που μαθαίνεται και βοηθά στην οπτικοποίηση της δυναμικής πλοήγησης.

3. Περιγραφή Υλοποίησης

Η υλοποίηση πραγματοποιήθηκε σε γλώσσα Python, με αξιοποίηση βιβλιοθηκών όπως numpy, matplotlib, pygame, torch & seaborn. Το σύστημα περιλαμβάνει διακριτά υποσυστήματα για την αναπαράσταση του περιβάλλοντος, την εκπαίδευση μέσω Q-learning και την καταγραφή κυψελιδωτής δραστηριότητας.

3.1. Περιβάλλον Πλέγματος

Το περιβάλλον προσομοιώνεται ως 2D πλέγμα $N \times N$, στο οποίο κάθε κελί μπορεί να είναι:

- Ελεύθερο (περιοχή πλοήγησης),
- Εμπόδιο (απαγορευμένη περιοχή),
- Στόχος (σημείο τερματισμού).

Η αρχική θέση του ρομπότ είναι σταθερά στο $(0, 0)$, ενώ ο στόχος τοποθετείται στο $(N-1, N-1)$. Τα εμπόδια τοποθετούνται τυχαία, αποφεύγοντας τις θέσεις εκκίνησης και στόχου.

Αυτό υλοποιείται μέσω της κλάσης GridEnvironment, η οποία παρέχει:

- Επαλήθευση εγκυρότητας κινήσεων (εντός ορίων, χωρίς πρόσκρουση),
- Ανάθεση ανταμοιβής ή ποινής (βάσει σύγκρουσης ή επιτυχίας),
- Τυχαία ανανέωση εμποδίων ανά επεισόδιο.

3.2. Εκπαίδευση με Q-learning

Ο πράκτορας εκπαιδεύεται χρησιμοποιώντας ε-greedy στρατηγική, με σταδιακή μείωση της πιθανότητας εξερεύνησης ε-decay. Σε κάθε βήμα:

1. Επιλέγεται ενέργεια (explore/exploit),
2. Πραγματοποιείται μετάβαση στο περιβάλλον,
3. Υπολογίζεται ανταμοιβή,
4. Ενημερώνεται ο πίνακας Q σύμφωνα με τον κανόνα Bellman.

Η διαδικασία επαναλαμβάνεται για προκαθορισμένο αριθμό επεισοδίων (200–500), με στατιστικά όπως ποσοστά επιτυχίας και αριθμός βημάτων να καταγράφονται. Ο κώδικας επιτρέπει αποθήκευση των τελικών πινάκων Q και grid, καθώς και την οπτική προβολή της διαδρομής (μέσω matplotlib ή pygame).

3.3. Κυψελιδωτό Αυτόματο (CA)

Παράλληλα με το Q-learning, υλοποιείται ένας πίνακας ίδιων διαστάσεων με το πλέγμα, ο οποίος λειτουργεί ως CA δραστηριότητας:

- Κάθε φορά που επισκέπτεται ένα κελί, η τιμή του αυξάνεται.
- Στο τέλος κάθε επεισοδίου εφαρμόζεται διάχυση (diffusion) στους γειτονικούς κόμβους.

→ Αυτός ο μηχανισμός παρέχει:

- Μνήμη πρόσφατης κινητικότητας του πράκτορα,
- Χάρτη hot zone του περιβάλλοντος,

Αν και δεν επηρεάζει άμεσα τη στρατηγική του πράκτορα, προσφέρει δυνατότητα για μελλοντική ενσωμάτωση στο reward function ή στην πολιτική.

4. Αποτελέσματα και Οπτικοποίηση


Μετά την εκπαίδευση του πράκτορα σε πλέγμα 10×10 για 200 επεισόδια, προέκυψαν τα ακόλουθα βασικά στατιστικά:

- Μέσος αριθμός βημάτων ανά επεισόδιο: 69.68
- Ποσοστό επιτυχίας (προσέγγιση στόχου): 100.00%
- Τελική τιμή εψίλον: 0.0816

4.1. Βέλτιστη Διαδρομή (Q-table)

Η τελική διαδρομή που παράγεται μετά την εκπαίδευση προκύπτει από εκμετάλλευση της Q-table, χωρίς τυχειότητα. Η πορεία απεικονίζεται σε δισδιάστατο γράφημα όπου:

- Οι μπλε κουκκίδες $\rightarrow$ εμπόδια,
- Η κόκκινη γραμμή $\rightarrow$ πορεία,
- Το πράσινο τετράγωνο $\rightarrow$ στόχο.




Σχήμα 1. Θερμικός χάρτης μέγιστων Q-τιμών για κάθε κελί μετά την εκπαίδευση

4.2. Χάρτης Δραστηριότητας CA

Παράλληλα, ο πίνακας CA εμφανίζει τη **συχνότητα επίσκεψης** των κελιών. Οι τιμές υψηλής δραστηριότητας εμφανίζονται σε θερμά χρώματα (π.χ., κόκκινο/πορτοκαλί), δείχνοντας τις περιοχές που εξερευνήθηκαν εντονότερα.

Αυτό επιτρέπει ερμηνεία στρατηγικής:

- Διαδρομές με υψηλό «βάρος» σημαίνουν προτιμημένες πορείες,
- Περιμετρικές κινήσεις ή αδιέξοδα εμφανίζονται με φθίνουσα ένταση.




Σχήμα 2. Real-time προβολή πλοήγησης και δραστηριότητας CA κατά την εκπαίδευση

4.3. Προσομοιώσεις σε πραγματικό χρόνο

Υλοποιήθηκαν επίσης εναλλακτικά σενάρια με `pygame`, τα οποία παρέχουν:

- Οπτικοποίηση online εκπαίδευσης (πράκτορας κινείται ενώ μαθαίνει),
- Εμφάνιση εμποδίων, διαδρομής και στόχου,
- Σε προηγμένες υλοποιήσεις (`dqn_zoomed_gui.py`), χρήση νευρωνικού δικτύου και `zoom` γύρω από το ρομπότ.

Παρόλο που οι προσομοιώσεις αυτές δεν οδήγησαν σε άμεσα βέλτιστη πλοήγηση λόγω πολυπλοκότητας ή μικρού αριθμού επεισοδίων, προσφέρουν χρήσιμη οπτική κατανόηση της διαδικασίας μάθησης και των προκλήσεων.



Σχήμα 3. Ανάλυση απόδοσης του πράκτορα σε 300 επεισόδια (ανταμοιβή, βήματα, επιτυχία)

5. Προτάσεις βελτίωσης

Παρά την επιτυχή ολοκλήρωση της πλοήγησης σε τυπικά σενάρια, εντοπίστηκαν σημεία που μπορούν να βελτιωθούν για πιο σύνθετα ή γενικευμένα περιβάλλοντα:

- Ευαισθησία στη διαμόρφωση εμποδίων: Σε ορισμένες τυχαίες διατάξεις, ο πράκτορας αποτυγχάνει να βρει βέλτιστη διαδρομή, υποδεικνύοντας αστάθεια της εκπαίδευσης σε πολύπλοκα περιβάλλοντα.
- Παθητική χρήση CA: Το Κυψελιδωτό Αυτόματο καταγράφει μεν τη δραστηριότητα στο πλέγμα, αλλά δεν επηρεάζει τη λήψη απόφασης κατά τη διάρκεια της μάθησης.
- Έλλειψη επαναληψιμότητας: Η χρήση πλήρως τυχαίας αρχικοποίησης χωρίς σταθερό seed δυσκολεύει τη σύγκριση μεταξύ εκτελέσεων και τον αξιόπιστο έλεγχο παραμέτρων.

Προτεινόμενες Βελτιώσεις:

- Ενεργή ενσωμάτωση του CA: Χρήση του CA ως μηχανισμού ενίσχυσης ή αποθάρρυνσης συγκεκριμένων διαδρομών. Για παράδειγμα:
 - Τροποποίηση του reward function βάσει τοπικής δραστηριότητας,
 - Ενίσχυση της εξερεύνησης περιοχών με χαμηλή επίσκεψη.
- Καθιέρωση επαναληψιμότητας: Χρήση σταθερού τυχαίου σπόρου (seed) για πειραματική αναπαραγωγιμότητα και δυνατότητα συγκρίσεων.
- Γενίκευση σε μεγαλύτερα πλέγματα: Μελέτη της συμπεριφοράς σε περιβάλλοντα με διαστάσεις $>10 \times 10$, όπου η ανάγκη για πιο κλιμακούμενες τεχνικές (π.χ. DQN) γίνεται εμφανής.

- Εναλλακτικά reward schemes: Προσθήκη κριτηρίων για επιβράβευση γρήγορων ή ευθυγραμμισμένων κινήσεων προς τον στόχο.
- Σενάρια περιορισμένης πληροφόρησης: Προσομοίωση πραγματικών αισθητήρων (π.χ., πεπερασμένη ορατότητα, αισθητήρες σύγκρουσης) για μεγαλύτερο ρεαλισμό.

6. Συμπεράσματα

Η παρούσα εργασία πραγματοποιήθηκε την πλοήγηση ενός ρομπότ σε περιβάλλον πλέγματος με τη χρήση **ενισχυτικής μάθησης τύπου Q-learning**, σε συνδυασμό με τη δυναμική καταγραφή του χώρου μέσω **Κυψελιδωτού Αυτομάτου (CA)**.

Η μέθοδος απέδειξε ότι μπορεί να επιτυγχάνει τα εξής:

- αυτόνομη εκμάθηση στρατηγικής πλοήγησης χωρίς προκαθορισμένο χάρτη,
- αποφυγή εμποδίων,
- επαναληπτικά επιτυχή προσέγγιση του στόχου,
- οπτική και ποσοτική ανάλυση της πορείας μέσω CA heatmaps.

Το CA, αν και παθητικό στην παρούσα φάση, προσέφερε επιπλέον πληροφόρηση για τη συμπεριφορά του πράκτορα στον χώρο, ανοίγοντας τον δρόμο για υβριδικές στρατηγικές μάθησης και κατανεμημένης απόφασης.

Παράλληλα, η εργασία ανέδειξε προκλήσεις όπως:

- η ευαισθησία στη γεωμετρία του περιβάλλοντος,
- η ανάγκη για αναπαραγωγιμότητα και κλιμακωσιμότητα,
- η αδυναμία του Q-learning σε πολύπλοκες καταστάσεις χωρίς νευρωνική γενίκευση.

Η μελλοντική επέκταση του έργου περιλαμβάνει την ενσωμάτωση προχωρημένων τεχνικών (π.χ. Deep Q Networks), καθώς και τη χρήση του CA ως ενεργό στοιχείο στρατηγικής, ακολουθώντας τις προσεγγίσεις που προτείνει η σύγχρονη βιβλιογραφία [Sirakoulis & Adamatzky, 2015].

Η εργασία τεκμηρίωσε επιτυχώς ότι η σύζευξη απλών υπολογιστικών μοντέλων (CA) με ενισχυτική μάθηση μπορεί να οδηγήσει σε πολύπλοκη και αποδοτική συμπεριφορά, ακόμη και σε περιβάλλοντα με αβεβαιότητα.

7. Περιγραφή Κύριων Αρχείων Προσομοίωσης

Στο πλαίσιο της εργασίας δημιουργήθηκαν συνολικά 4 σενάρια προσομοίωσης 1. Final, 2. Final_livelearn, 3. Deep learning και 4. True cecular. Τα final & final_livelearn είναι τα 2 βασικά σενάρια τα οποία προβάλλουν διαφορετικά στάδια της μάθησης του πράκτορα:

- **Final_10x10.py**

Το αρχείο αυτό εκτελεί την πλοήγηση του ρομπότ αφού έχει προηγηθεί η εκπαίδευση μέσω Q-learning. Η προσομοίωση απλώς προβάλλει τη βέλτιστη διαδρομή που έχει μάθει ο πράκτορας, χωρίς περαιτέρω μάθηση κατά την εκτέλεση.

→ Κατάλληλο για αξιολόγηση επιδόσεων και τελικής στρατηγικής.

- **Final_10x10_Live.py**

Σε αυτή την έκδοση, το περιβάλλον εκπαιδεύεται κατά τη διάρκεια της προσομοίωσης, εφαρμόζοντας ενισχυτική μάθηση με reward/penalty. Το Κυψελιδωτό Αυτόματο (CA) ενημερώνεται δυναμικά και επηρεάζει τον χάρτη δραστηριότητας.

→ Προσφέρεται για παρατήρηση της εξελικτικής μάθησης και σύγκριση συμπεριφοράς σε διαφορετικά επεισόδια.

Αμφότερες οι εκτελέσεις συνοδεύονται από δυνατότητα οπτικοποίησης (pygame), καθώς και από εξαγωγή στατιστικών επιδόσεων.

8. Τελικός κώδικας και επεξήγηση

Ο τελικός ενιαίος κώδικας (true_cesular.py) ενσωματώνει πλήρως τη λογική πλοήγησης ρομπότ μέσω Κυψελιδωτού Αυτομάτου και Ενισχυτικής Μάθησης. Περιλαμβάνει:

- Πλήρη ορισμό του πλέγματος, των κελιών και των καταστάσεών τους.
- Εκπαίδευση με Q-learning και soft ενημέρωση γειτονικών Q-values.
- Δυναμική καταγραφή φερομονών ως ένδειξη επισκεψιμότητας κελιών.
- Πλήρως οπτικοποιημένο γραφικό περιβάλλον (zoom + info panel).
- Αυτόματη εξαγωγή και παρουσίαση στατιστικών πλοήγησης και heatmaps.

Η οργάνωση του κώδικα και η χρήση αντικειμενοστραφών δομών καθιστά το σύστημα επεκτάσιμο για μελλοντική προσθήκη λειτουργιών όπως:

- πολλαπλοί πράκτορες,
- βελτιστοποίηση με swarm algorithms,
- εναλλασσόμενες συνθήκες περιβάλλοντος.

9. Εξέλιξη Υλοποίησης

Η ανάπτυξη του συστήματος πλοήγησης πραγματοποιήθηκε μέσω διαδοχικών εκδόσεων, καθεμία εκ των οποίων εισήγαγε βελτιώσεις ή νέες ιδέες. Η τελική μορφή προέκυψε μέσα από πειραματισμούς και ανατροφοδότηση.

► **Final.py**

Η αρχική έκδοση βασιζόταν σε κλασικό Q-learning με offline εκπαίδευση και εμφάνιση της τελικής διαδρομής. Η προσομοίωση λειτουργούσε μετά το πέρας της εκπαίδευσης.

► **Final_livelearn.py**

Σε αυτή την παραλλαγή, προστέθηκε δυνατότητα εκπαίδευσης κατά την προσομοίωση. Η λειτουργία reward/penalty ενεργοποιείται σε πραγματικό χρόνο και ο πράκτορας εξελίσσει τη στρατηγική του μέσα από συνεχή πλοήγηση.

► **dqn_zoomed_gui.py // DeepLearn**

Πραγματοποιήθηκε προσπάθεια ενσωμάτωσης **Deep Q-Learning** με νευρωνικό δίκτυο και zoomed γραφικό περιβάλλον για μεγάλα πλέγματα (π.χ. 200×200). Αν και ενδιαφέρουσα ως προσέγγιση, ο αλγόριθμος δεν κατέληξε σε αποτελεσματική στρατηγική εντός των περιορισμένων επεισοδίων και χρόνου.

► **true_cecular.py**

Ο τελικός κώδικας ενοποιεί τα επιμέρους στοιχεία σε μία πλήρη υλοποίηση:

- Οπτικοποίηση zoom γύρω από το ρομπότ,
- Q-learning με soft update σε γείτονες,
- Χρήση CA για καταγραφή επισκεψιμότητας,
- Καθαρό interface και γραφήματα απόδοσης.

Η πορεία αυτή αντανakλά την πρόοδο από βασική προσέγγιση σε πιο σύνθετο και επεκτάσιμο σύστημα.

10. Βιβλιογραφία

- Sirakoulis, G.C. & Adamatzky, A. (2015). *Robots and Lattice Automata*. Springer.
- Adamatzky, A., & Sirakoulis, G. C. (2024). Robot navigation with cellular automata: Survey and prospects. *Natural Computing*. <https://doi.org/10.1007/s11047-024-09975-4>
- Mohemmed, A., Schaefer, G., & Rajasegarar, S. (2018). A survey of reinforcement learning techniques for robotic decision-making. *Procedia Computer Science*, 133, 144–151. <https://www.sciencedirect.com/science/article/abs/pii/S1877750318303272>
- Silver, D., et al. (2016). Mastering the game of Go with deep neural networks and tree search. *Communications of the ACM*, 58(3), 103–113. <https://dl.acm.org/doi/abs/10.1145/2812808>
- Kollar, T., & Roy, N. (2011). Trajectory optimization using reinforcement learning for map exploration. *2011 IEEE International Conference on Robotics and Automation*. <https://ieeexplore.ieee.org/abstract/document/6095651/>
- Koenig, S., & Likhachev, M. (2005). Fast replanning for navigation in unknown terrain. *IEEE Transactions on Robotics*, 21(3), 354–363. <https://ieeexplore.ieee.org/abstract/document/5470700/>